Finding the hydrogen 21-cm signal

Inferring the reionization fraction from Gaussian and non-Gaussian data

Alex HOUTTUIN

Travail de bachelor 2026

Filière Informatique et systèmes de communication - Orientation Ingénierie des données

Professeur: Emmanuel DE SALIS

Expert: Nicolas CERARDI

Description

Comprendre comment l'univers primitif est passé de l'obscurité à la lumière durant l'Époque de Réionisation est un défi majeur de l'astronomie. Le futur radiotélescope géant SKAO produira des volumes de données massifs qu'il faut apprendre à analyser dès aujourd'hui grâce à l'intelligence artificielle. Dans le cadre du défi scientifique international SKA (SDC3b), l'objectif de ce projet est d'utiliser l'inférence basée sur les simulations (SBI) pour estimer la fraction d'hydrogène neutre à différentes époques cosmologiques. Nous comparons deux types de données : le spectre de puissance (variance d'énergie) et les nombres de Betti (topologie et formes physiques), afin de concevoir un pipeline prédictif optimal capable de fournir des incertitudes fiables.

Déroulement

- Recherche et astrophysique, nous assimilons des concepts cosmologiques (signal 21-cm, redshift) et étudions l'état de l'art du défi SDC3b.
- Préparation des données, nous traitons des simulations cosmologiques en trois époques chronologiques (z1, z2, z3) avec deux types de données (spectre de puissance, nombres de Betti).
- Nous développons six pipelines de Deep Learning, en utilisant un réseau ResNet-18 (spectre de puissance) et un MLP (Betti)
- Évaluation empirique, nous sélectionnons le meilleur modèle sur 30 essais selon la qualité de calibration (TARP) et validation sur un jeu de test global indépendant et évaluation des métriques R2, RMSE et MAE.

Résultats

L'analyse topologique (nombres de Betti) se révèle jusqu'à 7 fois plus précise que le spectre de puissance dans les dernières phases de la réionisation, lorsque l'univers est presque entièrement ionisé. De plus, la fusion des deux types de données dans un modèle d'ensemble conjoint atteint la meilleure précision globale (R2 = 99.53%). Enfin, regrouper 5 modèles en un ensemble élargit l'incertitude de 14% à 32%, offrant une marge de sécurité essentielle contre la surconfiance de l'IA face au bruit.

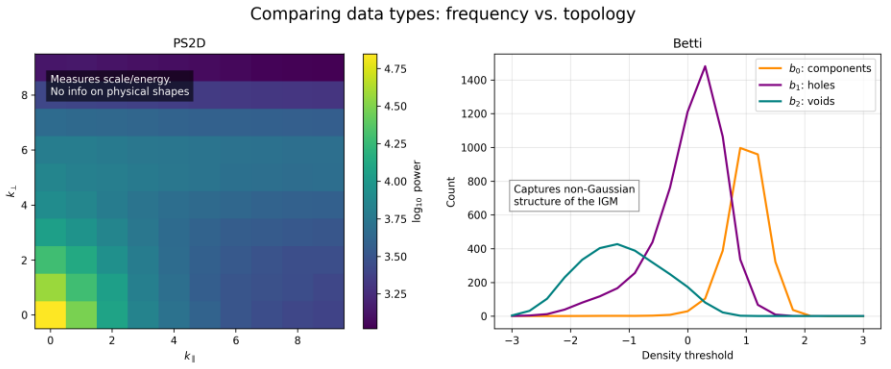


Figure 1 : Comparaison entre le spectre de puissance 2D (à gauche, mesurant l'énergie) et les nombres de Betti (à droite, capturant la structure non-gaussienne du milieu intergalactique).

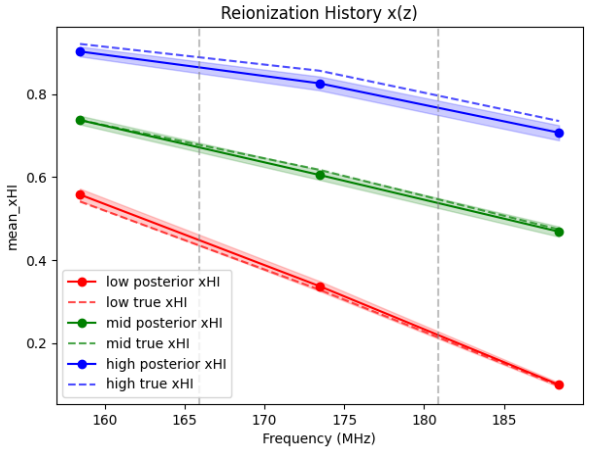


Figure 2: Chronologie de la réionisation inférée par notre modèle d'ensemble conjoint recommandé sur trois scénarios (rapide, moyen et lent), montrant l'évolution et l'incertitude de la fraction d'hydrogène neutre.

Discussion : Conclusions et perspectives

Ce travail démontre qu'une approche informatique et axée sur les données permet de résoudre des problèmes d'inférence cosmologiques. Pour le futur télescope SKA, nous recommandons l'utilisation du SBI 5-ensemble PS2D + Betti afin de garantir des prédictions prudentes face au bruit réel des observations. Les développements futurs seront d'améliorer ce pipeline en intégrant le protocole de FreB, en utilisant des contraintes empiriques du JWST comme trajectoires de référence, et en explorant les WST pour analyser directement les données brutes du télescope.